

EduMatrix 智教矩阵

过拟合

来源：对话同步

生成时间：2026年07月17日 15:11

标签：overfitting, regularization, bias-variance tradeoff, polynomial regression, ridge regression

```
mindmap
  root(("■■■■ Overfitting"))
    ■■■■
      ■■■■■■
      ■■■■■■
    ■■
      ■■■■■■
      ■■■■■■
      ■■■■■■
      ■■■■■■
    ■■■■
      ■■■-■■■■■
      ["■■■² + ■■ + ■■"]
      ["■■■■■■■■"]
      ■■■■■■
      ["L2■■■■■■■■"]
      ["■■■■■■■■"]
    ■■
```

```
■■■■■■■■■
■■■■■■■■■
■■■■■■■
■■■■■
■■■■(L1/L2)
■■■■■
■■■
■■■■■
Dropout
■■■■■
■■■■■
Rademacher■■■■■
■■■■■■■
■■■■■■■(NTK)
■■■■■■■
```

核心概念定义及背景

过拟合（Overfitting）是监督学习中最常见的泛化失败现象：模型在训练数据上达到极低误差，却在未见过的测试数据上表现显著恶化。其本质是模型过度学习了训练集中的随机噪声和异常模式，而非潜在的信号规律。

前置知识：多项式回归与基函数

考虑一元回归问题，真实数据生成过程为：

$$y = \sin(2\pi x) + \epsilon, \quad \epsilon \sim \mathcal{N}(0, 0.1^2)$$

我们采用 M 阶多项式作为基函数：

$$\phi_j(x) = x^j, \quad j = 0, 1, \dots, M$$

则模型为：

$$f(x; \mathbf{w}) = \sum_{j=0}^M w_j \phi_j(x) = \mathbf{w}^T \boldsymbol{\phi}(x)$$

其中 $\mathbf{w} = [w_0, w_1, \dots, w_M]^T$, $\boldsymbol{\phi}(x) = [1, x, x^2, \dots, x^M]^T$ 。

核心问题：当 M 很大（如 $M=15$ ）而训练样本数 $N=20$ 时，模型参数数量 $M+1=16$ 接近样本数，导致设计矩阵 $\mathbf{\Phi} \in \mathbb{R}^{N \times (M+1)}$ 可能存在列多重共线性，且高阶基函数在边界处数值不稳定。此时最小二乘解 $\mathbf{w}_{\text{LS}} = (\mathbf{\Phi}^T \mathbf{\Phi})^{-1} \mathbf{\Phi}^T \mathbf{y}$ 中的 $\mathbf{\Phi}^T \mathbf{\Phi}$ 接近奇异，权值 w_j 的方差极大，模型对观测噪声过度敏感。

偏差-方差分解与过拟合理论

固定输入 x ，记真实函数 $f(x) = \sin(2\pi x)$ ，噪声 ϵ 独立同分布且 $\mathbb{E}[\epsilon]=0$, $\text{Var}(\epsilon)=\sigma^2=0.01$ 。使用训练集 $\mathcal{D}$ 得到估计 $\hat{f}(x; \mathcal{D})$ 。则期望泛化误差可分解为：

\$\$

$\begin{aligned}$

$\mathbb{E}_{\mathcal{D}} \left[(y - \hat{f})^2 \right]$

$= \mathbb{E}_{\mathcal{D}} \left[(\epsilon + f - \hat{f})^2 \right]$

$= \sigma^2 + \underbrace{\mathbb{E}[(f - \mathbb{E}[\hat{f}])^2]}_{\text{Bias}^2} + \underbrace{\mathbb{E}[(\hat{f} - \mathbb{E}[\hat{f}])^2]}_{\text{Variance}}$

$\end{aligned}$

\$\$

- 低阶模型 ($M=1$)：偏差极高（线性函数无法逼近正弦曲线），但方差低（不同训练集拟合出的直线变化不大）。
- 高阶模型 ($M=15$)：偏差接近零（理论上可完美拟合正弦），但方差极大——模型会随着训练集噪声的随机偏移而剧烈振荡，造成测试误差飙升。

这是过拟合的核心数学描述：低偏差 + 高方差。

多项式回归实践示例

以下实验模拟 $N=20$ 个训练样本（含噪声）与 $N_{\text{test}}=500$ 个无噪声测试样本。对每个多项式阶数 $M \in \{1, 3, 9, 15\}$ ，计算训练/测试 MSE，并拟合曲线。同时，对 $M=15$ 引入 L2 正则化（岭回归），观察 λ 的影响。

关键代码占位符

实验中用于绘制误差曲线的代码已封装于以下占位符中，请原样保留，后处理将自动注入完整实现。


```

        x_poly = poly_features(x, self.deg)
        return self.linear(x_poly)

model = PolyReg(degree)
criterion = nn.MSELoss()
optimizer = optim.SGD(model.parameters(), lr=0.01)

# ----- ■■■■ + ■■ -----

epochs = 5000
train_losses, val_losses = [], []

for epoch in range(epochs):
    model.train()
    optimizer.zero_grad()
    y_pred = model(X_train)
    loss = criterion(y_pred, y_train)
    loss.backward()
    optimizer.step()

    model.eval()
    with torch.no_grad():
        y_pred_val = model(X_val)
        loss_val = criterion(y_pred_val, y_val)
    train_losses.append(loss.item())
    val_losses.append(loss_val.item())

    if (epoch+1) % 1000 == 0:
        print(f'Epoch {epoch+1:4d} | Train Loss: {loss.item():.4f} | Val Loss: {loss_val.item():.4f}')

# ----- ■■■ -----

plt.figure(figsize=(12,4))
plt.subplot(1,2,1)
plt.plot(train_losses, label='Train Loss')
plt.plot(val_losses, label='Val Loss')
plt.yscale('log')
plt.xlabel('Epoch')

plt.ylabel('MSE Loss')
plt.legend()
plt.title('Overfitting: Val Loss ■■')

plt.subplot(1,2,2)
plt.scatter(X_train.numpy(), y_train.numpy(), label='Train', alpha=0.7)
plt.scatter(X_val.numpy(), y_val.numpy(), label='Val', alpha=0.3, marker='x')
x_grid = torch.linspace(-0.2, 1.2, 200).reshape(-1,1)
with torch.no_grad():
    y_grid = model(x_grid)
plt.plot(x_grid.numpy(), y_grid.numpy(), 'r-', label=f'Degree {degree}')
plt.legend()
plt.title('■■■■■■■■')
plt.tight_layout()
plt.show()

```

运行后可见：训练 Loss 持续下降至极低，验证 Loss 在数百轮后反弹，此即过拟合典型信号。高次多项式在训练点间剧烈震荡，外推区完全偏离真实正弦函数。

正则化：L2 岭回归推导

目标函数：加入 L2 正则化后的损失函数

\$\$

$$J(\mathbf{w}) = \frac{1}{2N} \|\mathbf{y} - \mathbf{\Phi}\mathbf{w}\|^2 + \lambda \|\mathbf{w}\|^2$$

\$\$

求梯度并令为零，得正规方程：

\$\$

$$(\mathbf{\Phi}^T\mathbf{\Phi} + \lambda \mathbf{I})\mathbf{w} = \mathbf{\Phi}^T\mathbf{y}$$

\$\$

解为：

\$\$

$$\mathbf{w}^* = (\mathbf{\Phi}^T\mathbf{\Phi} + \lambda \mathbf{I})^{-1} \mathbf{\Phi}^T\mathbf{y}$$

\$\$

奇异值分解解释：设 $\mathbf{\Phi}^T\mathbf{\Phi} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$ ，其中 $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_{M+1})$ ，则：

\$\$

$$\mathbf{w}^* = \mathbf{V}(\mathbf{\Lambda} + \lambda \mathbf{I})^{-1} \mathbf{V}^T \mathbf{\Phi}^T\mathbf{y}$$

\$\$

每个特征值 λ_i 被衰减为 $\frac{\lambda_i}{\lambda_i + \lambda}$ 。当 $\lambda \rightarrow 0$ ，退化为普通最小二乘；当 $\lambda \rightarrow \infty$ ， $\mathbf{w}^* \rightarrow \mathbf{0}$ ，模型退化为常数拟合 $\hat{y} = \bar{y}$ 。L2 正则化对小奇异值对应的特征方向施加更强收缩（因为 $\frac{\lambda_i}{\lambda_i + \lambda}$ 在 λ_i 小时接近 0），这些方向通常对应高频噪声，从而有效降低方差。

高阶理论扩展

Rademacher 复杂度

衡量假设空间拟合随机噪声的能力。对于线性模型类 $\mathcal{F} = \{x \mapsto \mathbf{w}^T x \mid \|\mathbf{w}\|_2 \leq B\}$ ，有：

\$\$

$$\hat{\mathbb{E}}_S(\mathcal{R}(\mathcal{F})) \leq \frac{B}{\sqrt{N}} \sqrt{\text{tr}(\mathbf{X}^T\mathbf{X})}$$

\$\$

过拟合时，模型在训练集上的经验 Rademacher 复杂度高（能记忆噪声），测试集上泛化差。

双下降现象 (Double Descent)

现代高维过拟合并非单调：当模型参数数量等于数据点数量时，测试误差先上升（经典过拟合峰）后下降（插值相），形成双峰。该现象与良性过拟合 (Benign Overfitting) 相关——若噪声结构满足特定条件，插值解仍可泛化。

前沿研究方向

- 神经切线核 (NTK)：无限宽神经网络在梯度下降下等价于核方法，泛化边界由 NTK 矩阵条件数决定，过拟合程度与核谱分布相关。
- 隐式正则化：SGD 的噪声与早停对深度网络施加隐式 L2 正则化，权重趋向小范数。
- 元学习与正则化自动化：通过学习正则化策略（如 Meta-Regularization）动态调整 λ ，无需手工调参。

练习题与检索回顾

以下练习题改编自原始讲义，保留了原有全部核心问题，并增加了理论补充。

题目 1：多项式回归过拟合与正则化

背景：真实函数 $y = \sin(2\pi x) + \epsilon$ ， $N=20$ 个样本， M 次多项式拟合。

1. 实验分析：当 $M=3$ 和 $M=15$ 时，概念性描述训练/测试误差随 M 变化曲线。解释训练误差下降而测试误差上升的原因。
2. 正则化推导：写出 L2 正则化梯度下降更新规则，并说明 λ 的权重衰减作用。
3. 模型选择决策：给定验证集 MSE 对 λ 的结果，选择最优 λ 并解释偏差-方差权衡。

提示：梯度下降更新为 $\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \nabla_{\mathbf{w}} J$ ，其中 $\frac{\partial J}{\partial w_j} = \frac{1}{N} \sum_i (f(x_i) - y_i) x_i^j + \lambda w_j$ 。选择验证误差最小的 λ （本例中为 0.1），此时模型处于偏差与方差的平衡点。

题目 2：过拟合检测与交叉验证策略

背景：深度神经网络在 50000 张训练图像上准确率 99.8%，测试集 82.3%。

1. 诊断过拟合：列举至少 3 种方法（如训练/验证损失曲线、权重范数、学习曲线）。
2. 缓解策略：比较 L2 正则化、Dropout、早停的数学原理：
 - L2：直接惩罚权重范数，限制模型容量。
 - Dropout：通过随机丢弃神经元实现隐式模型集成，减少神经元共适应。
 - 早停：基于验证损失停止训练，防止权重过度增长。
3. 实践决策：写出 5 折交叉验证流程，并解释交叉验证平均准确率（85%）与测试准确率（82%）的差距可能意味着数据划分偏差或测试集分布微小偏移。

检索回顾题（闭卷）

1. 过拟合时训练误差与验证误差的趋势如何？文字描述。
2. 下列哪种方法不能直接缓解过拟合？

A. 增加训练数据量

- B. 降低模型复杂度
- C. 增加训练迭代次数
- D. 引入 L1/L2 正则化

（答案：C，因为增加迭代次数会加剧过拟合，除非配合早停）

拓展学习资源

以下视频资源可辅助理解过拟合的诊断与缓解策略：

- **【官方中英】2025年公认最好的【吴恩达机器学习课程】**：直观图表讲解过拟合与正则化，建议定位过拟合章节。
- **【本地动画】决策树动画**：复习决策树分裂机制，理解树模型中的过拟合表现。